

# UNIVERSIDAD CENTRAL DEL ECUADOR

Maestría en Estadística con mención en Ciencia de Datos e Inteligencia Artificial

Módulo 5: Optimización Matemática y Métodos Computacionales

## Optimización de la asignación muestral provincial para la estimación del rendimiento de cacao en Ecuador

Aplicación al Operativo de Rendimientos Objetivos Cacao 2025

**Estudiante:** Yeseña B. Muñoz C.

**Tipo de documento:** Informe técnico del Proyecto Integrador

**Área de aplicación:** Estadística agropecuaria y diseño muestral

**Fecha:** Agosto de 2026

# Índice

|                                                                               |           |
|-------------------------------------------------------------------------------|-----------|
| <b>1. Resumen</b>                                                             | <b>2</b>  |
| <b>2. Problema real y pregunta de decisión</b>                                | <b>2</b>  |
| 2.1. Tamaño planificado y registros disponibles . . . . .                     | 3         |
| <b>3. Datos, parámetros, supuestos y unidades</b>                             | <b>3</b>  |
| <b>4. Formulación matemática</b>                                              | <b>4</b>  |
| <b>5. Convexidad de la relajación y estructura discreta</b>                   | <b>5</b>  |
| <b>6. Métodos de solución y baseline</b>                                      | <b>5</b>  |
| 6.1. Baseline . . . . .                                                       | 5         |
| 6.2. Relajación CVXPY/CLARABEL . . . . .                                      | 6         |
| 6.3. Verificación mediante Neyman y KKT . . . . .                             | 6         |
| 6.4. Óptimo entero . . . . .                                                  | 6         |
| <b>7. Resultados principales</b>                                              | <b>7</b>  |
| <b>8. Optimalidad, KKT y dualidad</b>                                         | <b>8</b>  |
| 8.1. Derivación del problema dual . . . . .                                   | 9         |
| <b>9. Comparación con Differential Evolution</b>                              | <b>10</b> |
| <b>10. Validación estadística mediante bootstrap</b>                          | <b>10</b> |
| <b>11. Complejidad computacional y estabilidad numérica</b>                   | <b>11</b> |
| <b>12. Análisis de sensibilidad y escenarios</b>                              | <b>13</b> |
| 12.1. Sensibilidad al tamaño total $T$ . . . . .                              | 13        |
| 12.2. Sensibilidad a la cobertura mínima . . . . .                            | 14        |
| 12.3. Escenario de precisión provincial . . . . .                             | 14        |
| 12.4. Variabilidad histórica $S_h^{2024}$ frente a $S_h^{2025}$ . . . . .     | 14        |
| <b>13. Asignación provincial final</b>                                        | <b>15</b> |
| <b>14. Aporte institucional y recomendaciones para futuros levantamientos</b> | <b>16</b> |
| <b>15. Limitaciones</b>                                                       | <b>16</b> |
| <b>16. Conclusiones</b>                                                       | <b>17</b> |

## 1. Resumen

El Operativo de Rendimientos Objetivos (ORO) Cacao 2025 planificó una muestra total de 938 Unidades de Producción Agropecuaria (UPA) distribuida entre 21 provincias. Este proyecto estudia si ese mismo esfuerzo muestral puede redistribuirse de manera más eficiente para reducir la varianza de la estimación nacional del rendimiento.

La base final contiene 962 registros; 957 corresponden a operativos completos con un valor válido de rendimiento neto (RN). Los 957 registros se utilizan para estimar la variabilidad provincial observada en 2025, mientras que las 938 UPA se mantienen como restricción del problema para garantizar una comparación con el mismo tamaño total planificado.

La decisión real es discreta, por lo que el modelo final exige  $n_h \in \mathbb{Z}_+$ , donde  $n_h$  representa el número de UPA asignadas a la provincia  $h$ . Se estudia primero una relajación continua estrictamente convexa, resuelta con CVXPY/CLARABEL y verificada de forma independiente mediante la asignación de Neyman acotada derivada de las condiciones KKT. Posteriormente se obtiene el óptimo entero exacto con un algoritmo de ganancias marginales decrecientes.

La solución final entera mantiene las 938 UPA y reduce la varianza estimada en 35,24 % y el error estándar en 19,53 % respecto a la asignación oficial evaluada con la variabilidad observada en 2025. El costo de integralidad frente al óptimo relajado es únicamente 0,0034 %. La verificación CVXPY–Neyman presenta una diferencia de objetivo de  $2,553 \times 10^{-13}$ , y el gap primal–dual es  $3,388 \times 10^{-20}$ .

La robustez estadística se evaluó mediante 500 réplicas bootstrap estratificadas. La reducción media de varianza del óptimo entero fue 35,63 %, con IC95 % percentil de 34,04 % a 37,38 %, y la optimización mejoró al baseline en el 100 % de las réplicas. Como comparación global, Differential Evolution produjo soluciones enteras factibles, pero su mejor resultado quedó 8,24 % por encima del óptimo entero.

El resultado debe interpretarse como una referencia cuantitativa de eficiencia nacional, no como un reemplazo automático del diseño institucional. El análisis con  $S_h^{2025}$  es retrospectivo; para futuros operativos se recomienda utilizar variabilidad histórica, piloto o actualizada antes del levantamiento, junto con restricciones explícitas de precisión provincial y, cuando exista información, costos de campo y tasas de no respuesta.

## 2. Problema real y pregunta de decisión

El ORO Cacao busca generar estimaciones del rendimiento del cultivo a partir de mediciones realizadas en UPA de las provincias productoras. La metodología 2025 definió tamaños muestrales provinciales utilizando Muestreo Aleatorio Simple para variable cuantitativa, niveles diferenciados de confianza y error, y variabilidad histórica. La documentación metodológica estableció un levantamiento total planificado de 938 UPA para 21 provincias.

El proyecto no plantea que el diseño institucional sea incorrecto. La pregunta es complementaria: si el esfuerzo nacional se fija en las mismas 938 UPA, ¿existe una distribución provincial que reduzca la varianza de la estimación nacional del rendimiento?

### Pregunta de decisión:

*¿Cómo distribuir un total fijo de 938 UPA entre 21 provincias productoras de cacao para minimizar*

la varianza estimada del rendimiento nacional, manteniendo cobertura provincial y sin exceder la población disponible?

En términos institucionales, la solución optimizada funciona como una referencia numérica de comparación: permite medir cuánto podría cambiar la precisión nacional bajo distintas reglas de asignación, tamaños totales y coberturas mínimas, sin convertir el resultado matemático en una regla automática de planificación.

### 2.1. Tamaño planificado y registros disponibles

Considerar que, se tiene tres cantidades que cumplen funciones distintas:

**Cuadro 1:** Diferencia entre tamaño planificado y registros finales.

| Cantidad   | Significado                                   | Uso en el proyecto                                      |
|------------|-----------------------------------------------|---------------------------------------------------------|
| <b>938</b> | UPA planificadas en la metodología 2025       | Presupuesto muestral $T$ y baseline comparable          |
| <b>962</b> | Registros finales disponibles en la base 2025 | Descripción del levantamiento final; no se usa como $T$ |
| <b>957</b> | Registros completos con RN válido             | Estimación de $S_h^{2025}$ y bootstrap                  |

No se seleccionan arbitrariamente 938 filas de los 957 registros completos. Los 957 se utilizan para estimar parámetros de variabilidad; el número 938 representa la cantidad total que el optimizador debe distribuir. La documentación utilizada no permite atribuir la diferencia entre 938 y 962 a una causa específica, por lo que no se asume reemplazo, sobrecobertura u otra explicación sin evidencia adicional.

## 3. Datos, parámetros, supuestos y unidades

La base institucional contiene información del ORO Cacao 2025. Para el modelo se utilizan provincia, rendimiento neto anual (RN en t/ha) y estado del operativo (Completo/Incompleto). Se conservan los registros completos con RN no faltante. No se imputan los operativos incompletos y no se eliminan automáticamente valores extremos por IQR, porque esa decisión modificaría directamente las desviaciones estándar provinciales.

La población nacional de referencia es  $N = 225\,433$  UPA y se consideran  $H = 21$  provincias. La variable RN utilizada en los 957 registros completos presenta un rango de 0,1901 a 1,4725 t/ha.

**Cuadro 2:** Notaciones principales del modelo.

| Notación     | Descripción                                           | Tipo                | Unidad       |
|--------------|-------------------------------------------------------|---------------------|--------------|
| $n_h$        | UPA asignadas a la provincia $h$                      | decisión entera     | UPA          |
| $N_h$        | población estimada de UPA en $h$                      | parámetro           | UPA          |
| $N$          | población nacional estimada                           | parámetro           | UPA          |
| $W_h$        | = peso poblacional de la provincia                    | parámetro           | adimensional |
| $S_h^{2025}$ | desviación estándar de RN observada en 2025           | parámetro estimado  | t/ha         |
| $S_h^{2024}$ | desviación estándar histórica usada en el diseño 2025 | parámetro histórico | t/ha         |
| $T$          | tamaño total a distribuir                             | parámetro           | UPA          |
| $\ell_h$     | cobertura mínima provincial                           | parámetro           | UPA          |

En el escenario base se utiliza  $T = 938$  y  $\ell_h = 9$ . El valor 9 corresponde al menor tamaño provincial de la asignación oficial 2025 y se utiliza como una cota operativa de referencia, no como un mínimo estadístico universal. Por esa razón se somete posteriormente a análisis de sensibilidad.

El uso de  $S_h^{2025}$  convierte el ejercicio principal en un análisis retrospectivo, es decir, esta variabilidad se conoció después del levantamiento. Para planificación futura debería reemplazarse por información disponible ex ante, como  $S_h^{2024}$ , una muestra piloto o una actualización previa al operativo.

## 4. Formulación matemática

La varianza aproximada del estimador estratificado de la media nacional, con corrección por población finita, se representa como:

$$V(\mathbf{n}) = \sum_{h=1}^H W_h^2 S_h^2 \left( \frac{1}{n_h} - \frac{1}{N_h} \right).$$

Cada término combina tres elementos: importancia poblacional  $W_h$ , variabilidad  $S_h$  y tamaño muestral  $n_h$ . En general, una provincia grande y heterogénea contribuye más a la incertidumbre nacional; aumentar  $n_h$  reduce su contribución a la varianza.

**Formulación del problema:**

$$\begin{array}{ll}
\min_{\mathbf{n}} & \sum_{h=1}^H W_h^2 S_h^2 \left( \frac{1}{n_h} - \frac{1}{N_h} \right) \\
\text{sujeto a} & \sum_{h=1}^H n_h = T, \\
& \ell_h \leq n_h \leq N_h, \quad h = 1, \dots, H, \\
& n_h \in \mathbb{Z}_+.
\end{array}$$

Las restricciones tienen una interpretación directa, el total debe ser 938 UPA, cada provincia debe conservar una cobertura mínima y ninguna puede recibir más UPA que su población estimada.

## 5. Convexidad de la relajación y estructura discreta

El problema final es discreto porque  $n_h$  debe ser entero. Para estudiar sus propiedades se considera la relajación  $n_h \in \mathbb{R}_{++}$ . Definiendo

$$a_h = W_h^2 S_h^2 > 0,$$

la parte variable de la función objetivo es:

$$f(\mathbf{n}) = \sum_{h=1}^H \frac{a_h}{n_h}.$$

Para cada componente,

$$f_h''(n_h) = \frac{2a_h}{n_h^3} > 0, \quad n_h > 0.$$

Por tanto, el Hessiano de la relajación es diagonal y positivo:

$$\nabla^2 f(\mathbf{n}) = \text{diag} \left( \frac{2a_1}{n_1^3}, \dots, \frac{2a_H}{n_H^3} \right) \succ 0.$$

Las restricciones continuas son afines; en consecuencia, la relajación es estrictamente convexa y posee un óptimo global único. Esta propiedad permite utilizar CVXPY y verificar condiciones KKT y dualidad.

Para el problema entero, la reducción de objetivo al agregar una UPA al estrato  $h$ , cuando actualmente tiene  $k$  unidades, es:

$$\Delta_h(k) = \frac{a_h}{k} - \frac{a_h}{k+1} = \frac{a_h}{k(k+1)}.$$

Estas ganancias marginales son decrecientes, lo que permite construir el óptimo entero asignando cada unidad disponible al estrato con mayor beneficio marginal factible.

## 6. Métodos de solución y baseline

### 6.1. Baseline

El baseline es la asignación oficial planificada de 938 UPA. Se evalúa con la misma función objetivo y con  $S_h^{2025}$ , de manera que la comparación mida exclusivamente el efecto de redistribuir la muestra bajo la variabilidad observada.

El baseline presentó:

$$V_{\text{oficial}} \approx 7.4289 \times 10^{-5}, \quad SE_{\text{oficial}} \approx 0.008619.$$

## 6.2. Relajación CVXPY/CLARABEL

La relajación continua se formuló en CVXPY usando `inv_pos`, que respeta las reglas de Programación Convexa Disciplinada (DCP). El solver principal fue CLARABEL, con tolerancias de factibilidad y gap de  $10^{-9}$ .

El resultado obtenido es:

$$V_{\text{rel}}^* = 4.8106246 \times 10^{-5},$$

con estado `optimal`, 16 iteraciones y tiempo aproximado de 0,05685 segundos.

## 6.3. Verificación mediante Neyman y KKT

Sin cotas activas, las condiciones KKT producen la asignación clásica de Neyman:

$$n_h^N = T \frac{W_h S_h}{\sum_j W_j S_j}.$$

En la ejecución, la Neyman clásica dejó 10 provincias por debajo de la cota mínima de 9 UPA, por lo que no es factible para el modelo completo. Con cotas, la solución adopta la forma:

$$n_h(\nu) = \text{clip} \left( \sqrt{\frac{a_h}{\nu}}, \ell_h, N_h \right),$$

donde  $\nu$  se determina por bisección imponiendo  $\sum_h n_h = T$ .

La diferencia entre CVXPY y Neyman acotada fue:

$$\|\mathbf{n}_{\text{CVXPY}} - \mathbf{n}_{\text{Neyman}}\|_2 = 0.005898,$$

$$|V_{\text{CVXPY}} - V_{\text{Neyman}}| = 2.553 \times 10^{-13}.$$

Estas diferencias son numéricamente despreciables y confirman de forma independiente la solución de la relajación.

## 6.4. Óptimo entero

La solución final implementable se obtuvo con el algoritmo exacto de ganancias marginales. Su objetivo fue aproximadamente:

$$V_{\mathbb{Z}}^* = 4.8107897 \times 10^{-5},$$

con:

$$\sum_h n_h^* = 938, \quad n_h^* \in \mathbb{Z}_+.$$

El costo de integralidad respecto a la cota continua fue:

$$\frac{V_{\mathbb{Z}}^* - V_{\text{rel}}^*}{V_{\text{rel}}^*} \times 100 = 0.0034 \, \%.$$

Un redondeo balanceado simple habría generado un costo adicional de 0,1592 % respecto al óptimo entero, lo que justifica resolver explícitamente el problema discreto.

## 7. Resultados principales

La decisión entera final reduce la varianza respecto al baseline en:

$$\boxed{35.24 \, \%}$$


y el error estándar en:

$$\boxed{19.53 \, \%}.$$

La mejora se obtiene sin aumentar el tamaño total de muestra, cambia únicamente su distribución provincial.

**Cuadro 3:** Resultados principales.

| Indicador                    | Resultado               |
|------------------------------|-------------------------|
| Varianza baseline oficial    | $7.4289 \times 10^{-5}$ |
| Error estándar baseline      | 0.008619                |
| Varianza óptima relajada     | $4.8106 \times 10^{-5}$ |
| Varianza óptima entera       | $4.8108 \times 10^{-5}$ |
| Error estándar óptimo entero | 0.006936                |
| Reducción de varianza        | 35.24 %                 |
| Reducción de error estándar  | 19.53 %                 |
| Costo de integralidad        | 0.0034 %                |
| Suma de la solución entera   | 938 UPA                 |



**Figura 1:** Comparación entre la asignación oficial 2025 y la asignación óptima entera.

Los mayores aumentos se concentran en Manabí (+100 UPA), Guayas (+46), Esmeraldas (+44), Orellana (+39), Los Ríos (+28) y Sucumbíos (+23). Las mayores reducciones corresponden a El Oro (−41), Bolívar (−40), Azuay (−37), Zamora Chinchipe (−29), Santa Elena (−24) y Pichincha (−22).

La interpretación no es que las provincias con reducción necesiten menos atención en términos sustantivos. El modelo responde exclusivamente al objetivo de precisión nacional bajo  $W_h$ ,  $S_h$ ,  $T$  y las cotas impuestas. Cuando la publicación provincial es prioritaria, deben incorporarse restricciones adicionales.

## 8. Optimalidad, KKT y dualidad

Las condiciones KKT se verifican sobre la relajación convexa. Con multiplicador  $\nu$  para la restricción de suma y multiplicadores  $\alpha_h, \beta_h$  para las cotas, la estacionariedad es:

$$-\frac{a_h}{n_h^2} + \nu - \alpha_h + \beta_h = 0.$$

### 8.1. Derivación del problema dual

Para la relajación continua, defínase

$$a_h = W_h^2 S_h^2, \quad c = \sum_{h=1}^H \frac{a_h}{N_h}.$$

El problema primal puede escribirse como

$$\min_{\mathbf{n} > 0} \sum_{h=1}^H \frac{a_h}{n_h} - c$$

sujeto a

$$\sum_{h=1}^H n_h = T, \quad \ell_h - n_h \leq 0, \quad n_h - N_h \leq 0.$$

Sean  $\nu$  el multiplicador de la restricción de igualdad,  $\alpha_h \geq 0$  los multiplicadores de las cotas inferiores y  $\beta_h \geq 0$  los de las cotas superiores. El Lagrangiano es

$$L(\mathbf{n}, \nu, \boldsymbol{\alpha}, \boldsymbol{\beta}) = \sum_{h=1}^H \frac{a_h}{n_h} - c + \nu \left( \sum_{h=1}^H n_h - T \right) + \sum_{h=1}^H \alpha_h (\ell_h - n_h) + \sum_{h=1}^H \beta_h (n_h - N_h).$$

Definiendo

$$q_h = \nu - \alpha_h + \beta_h,$$

se tiene

$$\inf_{n_h > 0} \left( \frac{a_h}{n_h} + q_h n_h \right) = 2\sqrt{a_h q_h}, \quad q_h \geq 0.$$

Por tanto, el problema dual es

|                                                                                                                                                                                                                                                                                                                                            |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| $\begin{aligned} & \max_{\nu, \boldsymbol{\alpha}, \boldsymbol{\beta}} \quad 2 \sum_{h=1}^H \sqrt{a_h (\nu - \alpha_h + \beta_h)} - \nu T + \sum_{h=1}^H \alpha_h \ell_h - \sum_{h=1}^H \beta_h N_h - c \\ & \text{sujeto a} \quad \alpha_h \geq 0, \quad \beta_h \geq 0, \\ & \quad \quad \nu - \alpha_h + \beta_h \geq 0. \end{aligned}$ |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|

La variable  $\nu$  es libre. Dado que la relajación convexa admite un punto estrictamente factible respecto a las desigualdades, se cumple la condición de Slater y, por tanto, existe dualidad fuerte.

Además, de la ejecución final se tiene los siguientes residuos:

**Cuadro 4:** Verificación numérica de optimalidad de la relajación.

| Métrica                         | Valor                   |
|---------------------------------|-------------------------|
| Estacionariedad, norma infinito | $1.323 \times 10^{-23}$ |
| Factibilidad primal             | $2.274 \times 10^{-13}$ |
| Factibilidad dual               | 0                       |
| Complementariedad               | 0                       |
| Gap primal–dual                 | $3.388 \times 10^{-20}$ |
| Cotas inferiores activas        | 10                      |
| Cotas superiores activas        | 0                       |

El gap primal–dual prácticamente nulo constituye evidencia adicional de optimalidad. El multiplicador asociado a  $T$  se interpretó como precio sombra:

$$\frac{\partial v_{\text{rel}}^*}{\partial T} = -\nu^* \approx -5.642226 \times 10^{-8}.$$

Una diferencia finita central produjo  $-5.642234 \times 10^{-8}$ , con error absoluto  $7.85 \times 10^{-14}$ . Por tanto, el precio sombra es consistente numéricamente con el cambio marginal de la varianza óptima relajada ante pequeñas variaciones de  $T$ .

## 9. Comparación con Differential Evolution

Como método heurístico/global se implementó Differential Evolution sobre decisiones enteras factibles. Se utilizaron tres semillas (2026, 2027 y 2028), 100 iteraciones y 12 726 evaluaciones por ejecución.

**Cuadro 5:** Resultados de Differential Evolution.

| Semilla | Objetivo              | Tiempo (s) | Gap vs. óptimo entero |
|---------|-----------------------|------------|-----------------------|
| 2026    | $5.30 \times 10^{-5}$ | 9.37       | 10.08 %               |
| 2027    | $5.31 \times 10^{-5}$ | 7.93       | 10.30 %               |
| 2028    | $5.21 \times 10^{-5}$ | 10.21      | 8.24 %                |

La mejor heurística quedó 8,24 % por encima del óptimo entero. El algoritmo entero exacto tardó aproximadamente 0,00325 segundos, frente a un promedio de 9,17 segundos de Differential Evolution. En este problema, aprovechar la estructura convexa/separable es claramente preferible. Una heurística tendría mayor utilidad si el modelo futuro incluyera variables binarias, costos fijos, rutas u otras restricciones que destruyan la estructura actual.


## 10. Validación estadística mediante bootstrap

Se realizó bootstrap estratificado por provincia con  $B = 500$  réplicas. En cada réplica se remuestreó RN dentro de cada provincia, se reestimó  $S_h$ , se resolvió nuevamente la relajación y el problema entero, y se comparó la solución con el baseline.

**Cuadro 6:** Resultados bootstrap del óptimo entero.

| Métrica                     | Media    | IC95 % inf. | IC95 % sup. |
|-----------------------------|----------|-------------|-------------|
| Reducción de varianza       | 35.63 %  | 34.04 %     | 37.38 %     |
| Reducción de error estándar | 19.77 %  | 18.78 %     | 20.87 %     |
| Costo de integralidad       | 0.0041 % | 0.0015 %    | 0.0074 %    |

La proporción de réplicas en las que la solución entera mejoró el baseline fue 100 %. La significancia práctica indica que, la reducción no depende únicamente de una estimación puntual de  $S_h^{2025}$ , sino que permanece bajo el remuestreo de la variabilidad observada.



**Figura 2:** Distribución bootstrap de la reducción de varianza frente al baseline.

Los intervalos de asignación mostraron mayor variabilidad en provincias como Manabí, Los Ríos, Esmeraldas y Guayas, mientras que varias provincias pequeñas permanecieron frecuentemente en la cota mínima. El bootstrap captura incertidumbre asociada al rendimiento observado, pero no incertidumbre en  $N_h$ , costos de campo o no respuesta.

## 11. Complejidad computacional y estabilidad numérica

Para la formulación cónica de CVXPY, una referencia algebraica densa para la resolución del sistema KKT por iteración es  $O(H^3)$ , aunque la dispersidad y la estructura pueden reducir sustancialmente el costo práctico. La verificación Neyman/KKT tiene orden aproximado:

$$O\left(H \log \frac{1}{\varepsilon}\right).$$

Para el algoritmo entero exacto, si

$$R = T - \sum_h \ell_h,$$

la implementación con cola de prioridad requiere aproximadamente:


$$O(H + R \log H).$$

La escalabilidad se evaluó con  $H = 25, 100, 400, 1000$ .

**Cuadro 7:** Tiempos empíricos de escalabilidad.

| $H$  | CVXPY (s) | Neyman/KKT (s) | Entero exacto (s) |
|------|-----------|----------------|-------------------|
| 25   | 0.0131    | 0.00075        | 0.00413           |
| 100  | 0.0185    | 0.00089        | 0.01671           |
| 400  | 0.0402    | 0.00111        | 0.06981           |
| 1000 | 0.1125    | 0.00156        | 0.17602           |

La pendiente empírica log-log fue aproximadamente 0,565 para CVXPY y 1,019 para el algoritmo entero exacto. La pendiente de CVXPY no reproduce la referencia cúbica porque el rango probado combina costos fijos de canonicalización, dispersidad y estructura interna del solver; la referencia  $O(H^3)$  debe entenderse como una cota densa por iteración, no como una ley exacta del tiempo observado.



**Figura 3:** Escalabilidad empírica de los tres enfoques.

Respecto al condicionamiento, se obtuvo:

**Cuadro 8:** Números de condición relevantes.

| Matriz                         | Número de condición |
|--------------------------------|---------------------|
| Hessiano completo              | $2.112 \times 10^3$ |
| Hessiano en variables libres   | 18.49               |
| KKT reducido sin escala        | $5.461 \times 10^9$ |
| KKT reducido con escala $10^6$ | $5.465 \times 10^3$ |

El escalamiento utilizado mejora de forma importante la condición del sistema KKT. Esto ayuda

a explicar por qué la implementación escala el objetivo sin alterar el minimizador y refuerza la estabilidad numérica observada.

## 12. Análisis de sensibilidad y escenarios


El análisis de sensibilidad evalúa cuánto cambia la decisión al modificar parámetros o restricciones relevantes. Se analizaron el tamaño total  $T$ , la cobertura mínima  $n_{\min}$ , la regla de precisión provincial y la variabilidad histórica frente a la observada.

### 12.1. Sensibilidad al tamaño total $T$

**Cuadro 9:** Sensibilidad de la decisión entera al tamaño total.

| $T$  | Varianza | Error estándar | Máx. asignación |
|------|----------|----------------|-----------------|
| 800  | 0.000057 | 0.007577       | 168             |
| 938  | 0.000048 | 0.006936       | 200             |
| 1100 | 0.000040 | 0.006359       | 239             |
| 1300 | 0.000034 | 0.005813       | 286             |

Aumentar  $T$  reduce el error estándar, pero con beneficios marginales decrecientes. Manabí fue la provincia con mayor cambio absoluto cuando  $T$  se alejó del escenario base.




**Figura 4:** Sensibilidad del error estándar al tamaño total de muestra.

## 12.2. Sensibilidad a la cobertura mínima

**Cuadro 10:** Sensibilidad a la cobertura mínima uniforme.

| $n_{\min}$ | Varianza | Reducción vs. baseline | Cambio $L_1$ |
|------------|----------|------------------------|--------------|
| 5          | 0.000046 | 37.75 %                | 74           |
| 9          | 0.000048 | 35.24 %                | 0            |
| 15         | 0.000052 | 30.26 %                | 138          |
| 20         | 0.000056 | 24.11 %                | 278          |
| 25         | 0.000063 | 15.78 %                | 418          |

La cobertura mínima es una restricción muy influyente. A medida que aumenta, se protege la presencia provincial, pero se reduce la libertad para concentrar muestra donde más disminuye la varianza nacional.



**Figura 5:** Efecto de la cobertura mínima sobre la reducción de varianza.

## 12.3. Escenario de precisión provincial

Se calculó una cota mínima aproximada basada en los niveles de confianza y errores provinciales de la metodología, utilizando  $S_h^{2025}$ . Bajo esta regla, la varianza entera fue aproximadamente 0.000049, el error estándar 0.007017 y la reducción frente al baseline 33.71 %. La decisión cambió en distancia  $L_1 = 76$  respecto al escenario base. Imbabura fue la provincia donde la restricción de precisión generó el mayor cambio, porque su tamaño oficial de 9 UPA resultó inferior al requerimiento calculado con la variabilidad observada.

Este escenario muestra que es posible conservar una parte importante de la ganancia nacional y, al mismo tiempo, imponer criterios más explícitos de precisión territorial.

## 12.4. Variabilidad histórica $S_h^{2024}$ frente a $S_h^{2025}$

Con  $S_h^{2024}$ , la reducción de varianza fue 31.25 %, frente a 35.24 % utilizando  $S_h^{2025}$ . La decisión cambió en una distancia  $L_1 = 140$ , siendo Los Ríos la provincia más afectada.

Este resultado es central para la interpretación institucional: el óptimo depende de la información de variabilidad disponible. Por ello, la solución basada en 2025 es un benchmark ex post; una aplicación prospectiva debería utilizar una estimación disponible antes del levantamiento.

En conjunto, la cobertura mínima  $n_{\min}$  y la variabilidad provincial  $S_h$  son los elementos que producen los cambios más relevantes en la estructura de la asignación, mientras que el tamaño total  $T$  determina principalmente el nivel global de precisión alcanzable.

### 13. Asignación provincial final

La Tabla 11 presenta la asignación oficial y la decisión óptima entera final.

**Cuadro 11:** Comparación provincial: baseline oficial y solución óptima entera.

| Provincia                      | $N_h$          | $n_{\text{oficial}}$ | $n_{\text{obs}}$ | $S_{2024}$ | $S_{2025}$ | $n_{\text{opt}}$ |
|--------------------------------|----------------|----------------------|------------------|------------|------------|------------------|
| AZUAY                          | 295            | 46                   | 47               | 0.3600     | 0.1213     | 9                |
| BOLÍVAR                        | 5 474          | 51                   | 53               | 0.3100     | 0.1061     | 11               |
| CAÑAR                          | 1 183          | 21                   | 22               | 0.2300     | 0.1371     | 9                |
| CARCHI                         | 96             | 24                   | 23               | 0.2700     | 0.2012     | 9                |
| CHIMBORAZO                     | 154            | 17                   | 18               | 0.2100     | 0.1636     | 9                |
| COTOPAXI                       | 3 299          | 13                   | 15               | 0.1700     | 0.1188     | 9                |
| EL ORO                         | 3 164          | 53                   | 53               | 0.3600     | 0.2032     | 12               |
| ESMERALDAS                     | 35 598         | 110                  | 110              | 0.3200     | 0.2316     | 154              |
| GUAYAS                         | 31 056         | 80                   | 83               | 0.2700     | 0.2170     | 126              |
| IMBABURA                       | 198            | 9                    | 12               | 0.1500     | 0.2811     | 9                |
| LOS RÍOS                       | 45 270         | 127                  | 127              | 0.3500     | 0.1834     | 155              |
| MANABÍ                         | 47 308         | 100                  | 101              | 0.3100     | 0.2270     | 200              |
| MORONA SANTIAGO                | 204            | 26                   | 27               | 0.2600     | 0.1281     | 9                |
| NAPO                           | 5 187          | 34                   | 33               | 0.2800     | 0.1547     | 15               |
| ORELLANA                       | 16 698         | 35                   | 37               | 0.2500     | 0.2379     | 74               |
| PASTAZA                        | 110            | 29                   | 29               | 0.3000     | 0.0868     | 9                |
| PICHINCHA                      | 4 407          | 35                   | 36               | 0.2900     | 0.1525     | 13               |
| SANTA ELENA                    | 155            | 33                   | 33               | 0.3100     | 0.1086     | 9                |
| SANTO DOMINGO DE LOS TSÁCHILAS | 9 180          | 20                   | 21               | 0.1900     | 0.1609     | 28               |
| SUCUMBÍOS                      | 15 576         | 37                   | 38               | 0.2600     | 0.2078     | 60               |
| ZAMORA CHINCHIPE               | 821            | 38                   | 39               | 0.3100     | 0.1737     | 9                |
| <b>Total</b>                   | <b>225 433</b> | <b>938</b>           | <b>957</b>       | –          | –          | <b>938</b>       |

La asignación refleja la lógica  $n_h \propto W_h S_h$  en los estratos libres, modificada por las cotas. Diez provincias terminan en la cota mínima de 9 UPA. Esta concentración es precisamente la razón por la cual la solución debe interpretarse como una referencia de eficiencia nacional y no como una recomendación automática para producir estimaciones provinciales.

## 14. Aporte institucional y recomendaciones para futuros levantamientos

El principal aporte institucional es incorporar una etapa formal de optimización dentro de la planificación muestral. La metodología actual puede mantenerse como base y complementarse con una comparación de escenarios antes de aprobar la asignación definitiva.

El modelo aporta cinco elementos concretos:

1. *Referencia cuantitativa de eficiencia*: permite comparar la asignación institucional con una distribución que minimiza la varianza nacional bajo el mismo total.
2. *Identificación del valor marginal de la muestra*: indica en qué provincias una UPA adicional reduce más la incertidumbre.
3. *Cuantificación del costo de cobertura territorial*: permite medir cuánto se sacrifica en precisión nacional al elevar  $n_{\min}$ .
4. *Evaluación de presupuesto muestral*: permite estudiar qué ocurre con  $T = 800, 938, 1100, 1300$  u otros tamaños.
5. *Herramienta reproducible*: facilita actualizar parámetros y volver a resolver el diseño con nueva información.

Para futuros operativos se recomienda:

- Utilizar  $S_h$  histórica, una muestra piloto o una estimación actualizada antes del levantamiento.
- Definir explícitamente si la prioridad es precisión nacional, provincial o una combinación de ambas.
- Establecer cotas mínimas derivadas de requerimientos de precisión provincial cuando los resultados se publicarán por territorio.
- Incorporar costos  $c_h$  por provincia cuando exista información, reemplazando o complementando la restricción de tamaño con un presupuesto  $\sum_h c_h n_h \leq B$ .
- Considerar tasas de no respuesta, reemplazo y restricciones logísticas.
- Realizar análisis de sensibilidad antes de aprobar la muestra.
- Utilizar el óptimo matemático como apoyo a la decisión, no como sustituto del criterio técnico institucional.

## 15. Limitaciones

Las principales limitaciones son:

1. El objetivo principal minimiza la varianza nacional y no garantiza por sí solo precisión provincial.
2.  $N_h$  se considera conocido y fijo.
3.  $S_h^{2025}$  es retrospectivo y no estaba disponible al diseñar el operativo 2025.

4. El proyecto mantiene 938 como esfuerzo comparable aunque la base final tenga 962 registros; la causa de esa diferencia no está documentada en los insumos utilizados.
5. Se supone costo homogéneo por UPA.
6. KKT y dualidad corresponden a la relajación continua; la decisión final se valida separadamente como entera.
7. No se modelan explícitamente no respuesta, desplazamientos, rutas ni disponibilidad de técnicos.
8. El ejercicio ex post no prueba que una redistribución hubiera producido exactamente los mismos datos observados; cuantifica eficiencia bajo los parámetros estimados.

## 16. Conclusiones

- El proyecto integra formulación matemática, optimización, verificación y análisis estadístico dentro de un problema real de diseño muestral agrícola.
- La decisión final es una asignación entera de 938 UPA. La relajación continua es estrictamente convexa y fue resuelta con CVXPY/CLARABEL; la solución fue corroborada mediante Neyman acotada/KKT, con diferencias numéricas prácticamente nulas y gap primal–dual de  $3.388 \times 10^{-20}$ . El costo de pasar de la relajación al óptimo entero es solamente 0,0034 %.
- Frente al baseline oficial, la asignación entera reduce la varianza estimada en 35,24 % y el error estándar en 19,53 %. El bootstrap de 500 réplicas confirmó que la mejora es estable, con un IC95 % de 34,04 % a 37,38 % para la reducción de varianza. Differential Evolution fue factible pero menos eficiente, con un mejor gap de 8,24 % y tiempos de cómputo sustancialmente mayores.
- La sensibilidad mostró que  $T$ ,  $n_{\min}$  y  $S_h$  modifican de manera material la decisión. En particular, elevar la cobertura mínima reduce la ganancia nacional, evidenciando el compromiso entre eficiencia global y precisión territorial.

## Referencias

- [1] Dirección de Generación de Datos Agropecuarios. *Metodología de muestreo para Operativos de Rendimientos Objetivos – Cacao Almendra Seca 2025*. Subsecretaría de Información y Fomento de Comercialización Agropecuaria, junio de 2025.
- [2] Diamond, S. y Boyd, S. “CVXPY: A Python-Embedded Modeling Language for Convex Optimization”. *Journal of Machine Learning Research*, 17(83), 1–5, 2016.